



Trabajo Fin de Grado - Curso 2025/ 2026

Modelo de Cadenas de Markov Ocultas de tiempo continuo para la detección de tumores de cáncer de colon

Autor: Carlos Domínguez Llidó

Tutor: RUBÉN AMORÓS SALVADOR

Agradecimientos

Me gustaría empezar agradeciendo este trabajo a mi familia. A ellos no solo les debo todas las oportunidades que he tenido a lo largo de mi vida, sino también quién soy y los valores que me han transmitido desde siempre.

También a las personas que me han acompañado por el camino: a amigos, con quienes he compartido alegrías y penas, en especial a Pau y Chema; y a los profesores que me han formado y orientado, impulsándome siempre a dar lo mejor de mí.

Finalmente y más importante, este trabajo se lo dedico a Dios, que siempre nos acompaña aunque no lo sepamos ver, y a mi abuelo Pascual, sin él nunca habría conseguido ser la persona que soy ahora. Ojalá estuvieras aquí con nosotros.

Carlos Domínguez Llidó
Junio de 2026

Resumen

El cáncer colorrectal (CRC) es el tercer tipo de cáncer más diagnosticado y la segunda causa de muerte por cáncer a nivel mundial; sin embargo, si se detecta en fases tempranas, esta enfermedad es perfectamente tratable. Por ello, la mejora del diagnóstico de esta enfermedad es necesaria. Actualmente la forma habitual de detección es mediante Tomografías Axiales Computarizadas (TAC), aunque esta forma de detección es imperfecta y conlleva un elevado coste para la sanidad. Diversos estudios indican que el análisis de ADN tumoral circulante (VAF) en la sangre es un biomarcador no invasivo y de gran fiabilidad para la detección de la enfermedad residual mínima en este tipo de patología. En este trabajo presentamos un modelo jerárquico Bayesiano capaz de detectar cambios en el nivel de este biomarcador, indicando así avances en el desarrollo de la enfermedad. El modelo aplica la información de los niveles de VAF del paciente y de los diagnósticos por TAC para construir una cadena de Markov con dos estados mostrando la presencia o ausencia del tumor. Aplicamos este modelo a los datos de seguimiento postcirugía de extirpación de tumor de CRC, analizando la fiabilidad y el desempeño del modelo, así como a datos sintéticos para evaluar la capacidad de recuperación de parámetros y de detección.

Índice general

Índice general	3
1. Introducción	5
2. Marco Teórico	7
2.1. Estadística Bayesiana	7
2.1.1. Introducción al enfoque Bayesiano	8
2.1.2. Clasificación de distribuciones de probabilidad en estadística Bayesiana	8
2.1.3. Distribuciones Prior	9
2.1.4. Los contrastes de hipótesis	10
2.1.5. Modelos Jerárquicos	12
2.1.6. Métodos de estimación	13
2.2. Cadenas de Markov	15
2.3. Análisis de Supervivencia	18
3. Metodología	20
3.0.1. Notación	20
3.1. Datos Clínicos	20
Figura 3.1: Diagnósticos de los datos clínicos	22
3.2. Modelo para la detección del tumor mediante VAF	23
Figura 3.2: Diagrama resumen del Modelo	23
3.3. Datos Sintéticos	27
Figura 3.3: Datos sintéticos para el entrenamiento	28
4. Resultados	29
4.1. Inferencia y Predicción	29
4.1.1. Inferencia	29
Figura 4.1: Traza MCMC con los datos originales	30
Cuadro 4.1: Estadístico Gelman-Rubin	30
Figura 4.2: Traza MCMC con seguimientos cortos	31
Cuadro 4.2: Estadístico ESS	31
Figura 4.3: Traza MCMC con seguimientos largos	32
Cuadro 4.3: Resúmenes numéricos de las cadenas	32
4.1.2. Predicción	33

Figura 4.4: Datos sintéticos para la predicción	33
Figura 4.5: Gráficas ROC	35
5. Discusión y Conclusiones	38

Capítulo 1

Introducción

Según la Agencia Internacional de Investigación del Cáncer[16, 31], en 2022 se diagnosticaron 1.926.425 casos de cáncer colorrectal (CRC) colocándose como el tercero más común, además de ser el segundo tipo de cáncer con mayor mortalidad, presentando una tasa global del 46,93 %.

La mayoría de los casos de CRC tienen como origen uno o varios adenomas benignos [11] que, tras invadir la submucosa, comienzan a ser perjudiciales para el paciente. En ese momento comienza lo que se llama cáncer preclínico, periodo en el que el adenoma maligno no provoca síntomas pero continúa creciendo desde estadio I (localizado) hasta estadio IV (metástasis). Una vez que comienzan a provocar síntomas, es diagnosticado como cáncer clínico. Pese a que entre el 40 % y el 50 % de la población mundial desarrolla uno o varios adenomas a lo largo de su vida, solo entre el 5 y el 6 % terminan desarrollando CRC. Otras causas conocidas del CRC son el síndrome de Lynch, síndrome de Peutz-Jeghers y la fibrosis quística, entre otros [1]. Factores como la genética, el ambiente y los hábitos intestinales son determinantes para la patogénesis del CRC. Por otro lado, esta enfermedad presenta síntomas comunes también en pacientes sanos, como son el cansancio, sangre en las heces o la pérdida de peso. Como consecuencia, el diagnóstico suele realizarse en fases avanzadas de la enfermedad y, por ello, se han tomado varias medidas para la prevención y el diagnóstico precoz de esta enfermedad en los últimos años, como las campañas impulsadas por la Unión Europea de test FOBT (también conocidos como test PDSOH). Sin embargo, muchas de estas medidas no son aplicables en países con recursos sanitarios limitados o de gran población donde los casos y la mortalidad de esta enfermedad aumentan significativamente. Con todo esto, la detección en pacientes suele ser tardía, provocando que muchos de los casos se encuentren en estadios muy avanzados e inoperables.

Incluso tras la extirpación quirúrgica del tumor, un elevado porcentaje de pacientes desarrolla recurrencia. El riesgo de reincidencia es significativamente elevado para los pacientes en estadio III, en los que alcanza una tasa de recaída del 30 % [28]. Con el objetivo de monitorizar y prevenir la reaparición de la enfermedad, se realiza un seguimiento a los pacientes operados de una duración de 5 años. Durante los primeros dos o tres años, se suelen realizar análisis de sangre y revisiones por imagen cada 3 o 6 meses, mientras que para los siguientes años los controles son más espaciados, cada 6 o 12 meses. Tras el seguimiento, algunos pacientes mantienen revisiones anuales para cerciorarse de no haber recaído. Todo este seguimiento en muchos casos va acompañado de sesiones de quimioterapia adyuvante (ACT), aunque cada seguimiento se trata de ajustar al caso concreto de cada paciente. El estudio GALAXY 2024 demostró que la ACT se asoció con una mejoría de la supervivencia libre de

recurrencia [22], sin embargo, este tratamiento es muy agresivo y es preferible no hacer uso excesivo de este, salvo en caso de necesidad.

La prueba por excelencia para la detección de CRC es la biopsia de tejido; sin embargo, este método presenta varias limitaciones debido a sus costes y adquisición. Esto lleva a los sanitarios a aplicar la detección radiológica por imagen (TAC), que continúa presentando problemas, como son la administración de los recursos sanitarios y el diagnóstico tardío, ya que el tumor solo es visible por imagen varios meses después de desarrollarse. Investigaciones recientes muestran que el análisis del nivel de ADN tumoral circulante (ctDNA), o Variant Allele Frequency (VAF), mediante biopsia líquida, es un biomarcador no invasivo y de gran fiabilidad no solo para la medición de la respuesta a la ACT sino también para la detección de enfermedad residual mínima (ERM). El objetivo de este estudio es investigar la aplicación de este biomarcador para el desarrollo de un modelo Bayesiano capaz de predecir la aparición del tumor antes de que sea visible por imagen. Con este modelo no solo se mejoraría el análisis de la reincidencia de los pacientes, sino también el seguimiento de estos, permitiendo una mejor organización y gestión de los recursos sanitarios.

El modelo se basa en el uso de Cadenas de Markov ocultas que simulan el desarrollo de la enfermedad. Esta cadena tiene dos estados que determinan la presencia o ausencia del tumor en el paciente. Además, el modelo también considera el diagnóstico imperfecto que conlleva la práctica del seguimiento por imagen, ya que existe la posibilidad de que el tumor esté presente pero se hayan cometido errores en el análisis de la imagen. Enfoques similares se han aplicado en distintos tipos de cáncer, como pueden ser el cáncer de ovario o el carcinoma hepatocelular (HCC). Este trabajo se basa en el modelo desarrollado por Amoros et al. sobre el HCC [2].

El capítulo 2 del documento se dedica a la introducción del enfoque Bayesiano en la estadística y de herramientas clave para el desarrollo del modelo como son las cadenas de Markov o el análisis de supervivencia. Posteriormente, en el capítulo 3, se explica detalladamente cada capa del modelo desarrollado y el método de estimación de los parámetros de este, prosiguiendo en el siguiente capítulo con un análisis de su rendimiento predictivo con pacientes de prueba. Finalmente, el último capítulo recoge la discusión de los resultados y las conclusiones de este trabajo.

Tanto el código como los datos usados en este trabajo se pueden encontrar en el repertorio de GitHub “Modelo-Deteccion-CRC”, url: <https://github.com/carlos-do-lli/Modelo-Deteccion-CRC/tree/main>.

Capítulo 2

Marco Teórico

El objetivo de este trabajo es modelizar la aparición de un suceso complejo, como es el tumor cancerígeno, a lo largo del tiempo. Para lograrlo es necesario aplicar un enfoque Bayesiano. Los sistemas biológicos suelen presentar comportamientos jerárquicos y una gran variabilidad que la estadística frecuentista no permite representar de la mejor forma posible. Por el contrario, la estadística Bayesiana propone un enfoque que permite replicar estos comportamientos de manera natural.

Por otra parte, existen herramientas estadísticas, como las Cadenas de Markov y el Análisis de Supervivencia son fundamentales en casos como el que queremos estudiar. Ambas herramientas son muy utilizadas en el ámbito bioestadístico para estudiar el avance de una enfermedad, ya que las Cadenas de Markov permiten hacer el estudio a lo largo del tiempo y el Análisis de Supervivencia es idóneo para contabilizar el riesgo.

La intención de este apartado es introducir los conceptos que acabamos de presentar, además de algunos de los resultados principales de los cuales haremos uso a lo largo del desarrollo del modelo.

2.1. Estadística Bayesiana

El origen de la distinción entre los dos enfoques de la estadística radica en cómo se entiende la probabilidad. La estadística Bayesiana constituye un enfoque inferencial fundamentado en la interpretación de la probabilidad como una medida racional de incertidumbre o de creencia, permitiendo actualizar el conocimiento previo mediante el Teorema de Bayes. A diferencia de la estadística Frecuentista, que interpreta la probabilidad en términos de frecuencias relativas en infinitas observaciones hipotéticas, el paradigma bayesiano incorpora información previa al proceso de estudio, lo que permite crear un marco flexible y coherente para el análisis de estudios complejos. Según Edwin Jaynes [17], la teoría bayesiana puede entenderse como una extensión de la lógica aplicada al razonamiento bajo incertidumbre, mientras que autores como Bruno de Finetti [7] destacan el carácter subjetivo y coherente de la probabilidad en la toma de decisiones científicas.

Dejando de lado las disputas metodológicas entre ambas vertientes, una de las principales razones por las que la corriente Bayesiana no tuvo una primera buena acogida fue la complejidad de los cálculos requeridos. Por esto no es de extrañar que con el aumento de la complejidad de los estudios y los distintos avances tecnológicos cada vez sea mayor el número de estadísticos que apoyan este enfoque.

2.1.1. Introducción al enfoque Bayesiano

Supongamos que se lanza una moneda diez veces obteniendo como resultados 6 caras y 4 cruces. Este suceso claramente sigue una distribución binomial $X \sim Bi(n = 10, \pi)$, donde π es la probabilidad de obtener cara en un lanzamiento. Desde el enfoque Frecuentista clásico, se consideraría como estimación para π el valor que maximizara la función de verosimilitud, en este caso $\hat{p} = \frac{6}{10} = 0,6$.

Por otro lado, el estadista Bayesiano antes de observar los resultados obtenidos y comenzar la estimación consideraría una distribución prior no informativa para π , como por ejemplo $\pi \sim Be(1, 1)$. Posteriormente consideraría los datos del experimento para actualizar la distribución prior:

$$\begin{aligned}\mathbb{P}(\pi|x) &= \frac{\mathbb{P}(\pi, x)}{\mathbb{P}(x)} = \frac{\mathbb{P}(x|\pi) \mathbb{P}(\pi)}{\mathbb{P}(x)} \propto \mathbb{P}(x|\pi) \mathbb{P}(\pi) \propto \\ &\propto [\pi^6(1-\pi)^4] [\pi^{1-1}(1-\pi)^{1-1}] = \pi^6(1-\pi)^4 = \pi^{7-1}(1-\pi)^{5-1}\end{aligned}$$

Donde x es la muestra obtenida del experimento.

Así pues, la distribución posterior de π es $Be(1+6, 1+4)$ y se seleccionaría como estimador la esperanza, en este caso $\hat{p} = \mathbb{E}[\pi|x] = \frac{7}{7+5} \approx 0,58$.

Aunque sea un ejemplo simple, sirve para ilustrar cómo la metodología Bayesiana incorpora más información al modelo. Sin embargo, este método conlleva cálculos más complejos y el problema de la elección acertada de una distribución prior.

En este ejemplo hemos hecho uso de $\mathbb{P}$ para hacer referencia a la probabilidad, sin embargo, a lo largo del capítulo usaremos la letra p para representar una función de probabilidad genérica.

2.1.2. Clasificación de distribuciones de probabilidad en estadística Bayesiana

En el ejemplo hemos hablado de distribuciones prior y posterior; estos son conceptos fundamentales en la estadística Bayesiana.

Dada una variable aleatoria, X , cuya función de probabilidad es $X \sim p(x|\theta)$ con θ como parámetro, llamamos distribución prior o a priori a la distribución asignada al parámetro $\theta \sim p(\theta|\nu)$ e hiperparámetros a los parámetros de esta, ν .

Por otro lado, si $x = (x_1, x_2, \dots, x_n)$ es una muestra aleatoria, podemos definir la distribución posterior como la probabilidad del parámetro θ condicionada a los datos, $p(\theta|x)$, que podemos calcular haciendo uso del Teorema de Bayes tal y como se muestra en el ejemplo:

$$p(\theta|x) = \frac{p(\theta, x)}{p(x)} = \frac{p(\theta, x)}{p(x)} = \frac{p(x|\theta)p(\theta)}{p(x)}$$

Por otro lado, esto nos hace preguntarnos cuál es el valor de $p(x)$, lo que llamamos distribución marginal y que denotamos en algunas ocasiones como $m(x)$, aunque también es llamada distribución prior predictiva. Esta se puede calcular variando el valor del parámetro:

$$p(x) = \begin{cases} \int p(x|\theta)p(\theta)d\theta & \text{en caso de variable continua} \\ \sum_{\theta} p(x|\theta)p(\theta) & \text{en caso de variable discreta} \end{cases}$$

Así pues, podemos considerar $p(\theta|x) \propto p(x|\theta)p(\theta)$.

Por otro lado, el teorema de Bayes se puede aplicar secuencialmente, es decir, si consideramos dos muestras independientes x_1, x_2 :

$$p(\theta|x_1, x_2) \propto p(x_1, x_2|\theta)p(\theta) = p(x_1|\theta)p(x_2|\theta)p(\theta) \propto \begin{cases} p(x_1|\theta)p(\theta|x_2) \\ p(x_2|\theta)p(\theta|x_1) \end{cases}$$

De esta forma podemos conocer la distribución posterior del conjunto (x_1, x_2) obteniendo primero la posterior de un conjunto y después de otro. Esto es la base de la predicción Bayesiana.

Partiendo de la independencia entre variables, dada una muestra independiente x podemos definir la distribución posterior predictiva como la función de probabilidad de futuras observaciones $\tilde{x}$ condicionada a la muestra:

$$p(\tilde{x}|x) = \int p(\tilde{x}, \theta|x) d\theta = \int p(\tilde{x}|\theta, x)p(\theta|x) d\theta = \int p(\tilde{x}|\theta)p(\theta|x) d\theta$$

Esto se conoce como aprendizaje Bayesiano y es una práctica muy común en el desarrollo de modelos de inteligencia artificial, ya que permite refinar las predicciones de forma natural a medida que se adquiere nueva información.

2.1.3. Distribuciones Prior

Con todo esto ya tenemos definida la estructura de un modelo Bayesiano. Sin embargo, como se ha mencionado previamente, la elicitación de una distribución prior queda a la elección del estadista, lo que provoca que haya distintas filosofías al respecto.

Aunque algunos autores suelen apoyarse en estudios pasados y opiniones de expertos en el tema de estudio, siempre suelen hacerse distintas asunciones tanto inconscientes, ya que tendemos a la sobreconfianza, como conscientes, con el objetivo de simplificar y recortar el tiempo de estudio. Por ello, con el objetivo de evitar estas asunciones, se hace uso de prior vagas u objetivas que no aportan información extra al experimento.

El concepto de prior objetiva está muy ligado a la noción de prior referente. No hay un consenso en cuanto a su definición formal, pero podemos considerar la definición de Kass y Wasserman [19]: es la distribución prior convencional o “por defecto”; o la de Bernardo [4]: es una prior que representa ignorancia respecto a θ en algún sentido formal.

A primera vista, la distribución uniforme parece ser la distribución objetiva por excelencia ya que les otorga a todos los posibles valores del parámetro la misma probabilidad. Si contamos con un espacio de parámetros discreto o acotado no hay ningún problema, pero si nos encontramos con $(-\infty, \infty)$ como espacio de parámetros ya no está tan claro, ya que aquí la distribución uniforme apropiada sería $p(\theta) = c$ para cualquier $c > 0$ y de esta forma la distribución es impropia:

$$\int_{-\infty}^{+\infty} p(\theta) d\theta = \int_{-\infty}^{+\infty} c d\theta = \infty$$

Sin embargo, hay algunos casos en los que es posible trabajar con prior impropias, aunque no es lo común. Si la integral de la función de verosimilitud respecto de θ converge a un valor finito K se puede continuar con la inferencia Bayesiana ya que resulta en una densidad posterior propia:

$$p(\theta|x) = \frac{p(x|\theta) \cdot c}{\int_{-\infty}^{+\infty} p(x|\theta) \cdot c d\theta} = \frac{p(x|\theta)}{K} \rightarrow \int_{-\infty}^{+\infty} p(\theta|x) d\theta = 1$$

Otro problema que presenta la uniforme es que no es invariante respecto a reparametrizaciones. Basta con considerar la prior $p(\theta) = 1$ si $\theta > 0$ y aplicar el cambio de variable $\gamma = \log(\theta)$ para ver que el resultado $\bar{p}(\gamma) = e^\gamma$, $-\infty < \gamma < \infty$ claramente no es uniforme. Por tanto, es posible que la ignorancia respecto a θ no implique ignorancia respecto a γ . Así pues, para que una prior sea objetiva es necesario que sea invariante respecto a reparametrizaciones.

Una de las distintas soluciones ante este problema es la prior de Jeffreys [18] ya que permite adaptarse al contexto del modelo:

$$p(\theta) \propto [I(\theta)]^{1/2} \text{ donde } I(\theta) = -\mathbb{E}_{x|\theta} \left[\frac{\partial^2}{\partial \theta^2} \log(f(x|\theta)) \right] \text{ es la información de fisher del modelo.}$$

La prior de Jeffreys no solo es relativamente sencilla computacionalmente sino que además es invariante. Hasta ahora hemos hablado de distribuciones prior no informativas, pero también es posible elicitarse una prior que otorgue información base al modelo. Sin embargo, hay que ser muy cauteloso con este tipo de elecciones, la elicitación informativa no se reduce solo a saber incluir de manera correcta la información en términos de distribución; también hay que cerciorarse de que esta información sea correcta. Teniendo esto en mente, Jeremy Oakley y Tony O'Hagan desarrollaron el programa SHELF (Sheffield Elicitation Framework) [24]. Para una correcta elicitación informativa son necesarios un experto en el tema de estudio y un facilitador capaz de traducir el conocimiento del experto en términos estadísticos. SHELF no solo contiene herramientas informáticas de R capaces de hacer los cálculos necesarios, sino que también contiene una serie de documentos diseñados para guiar tanto al experto como al facilitador, además de distintas plantillas con notas de los desarrolladores para registrar las elicitaciones. Gracias a todo esto, SHELF es el principal protocolo de elicitación seguido por los estadísticos Bayesianos actualmente.

Otra posible práctica son los métodos que hacen uso del análisis Bayesiano empírico, el cual hace uso de la distribución marginal para buscar una prior adecuada que preserve coherencia con esta. Aunque para muchos autores este tipo de métodos va en contra de la filosofía Bayesiana ya que hacen uso de los datos dos veces, una para el cálculo de la prior y otra para la verosimilitud.

Dejando el problema metodológico y filosófico al margen, muchas veces se seleccionan distribuciones de la misma familia que simplifican la expresión de la función de verosimilitud para así simplificar los cálculos. Por ejemplo, dada una variable $X \sim Po(\theta)$, la distribución $\theta \sim Ga(\alpha, \beta)$ es una prior conjugada ya que hace que la distribución posterior sea proporcional a una $Ga\left(x + \alpha, (1 + 1/\beta)^{-1}\right)$:

$$p(\theta|x) = p(x|\theta) p(\theta) = \left(\frac{e^{-\theta} \theta^x}{x!} \right) \left(\frac{\theta^{\alpha-1} e^{-\frac{\theta}{\beta}}}{\Gamma(\alpha) \beta^\alpha} \right) \propto \left(e^{-\theta} \theta^x \right) \left(\theta^{\alpha-1} e^{-\frac{\theta}{\beta}} \right) = \theta^{x+\alpha-1} e^{-\theta \left(1 + \frac{1}{\beta}\right)}$$

2.1.4. Los contrastes de hipótesis

Pese a que no se utilicen en este trabajo, los contrastes de hipótesis constituyen una de las principales herramientas en la estadística y estos también varían al usar un enfoque Bayesiano. Por tanto, es conveniente hablar de esta diferencia entre los enfoques.

El contraste de hipótesis clásico, basado en las ideas de Neyman y Pearson, consiste en enfrentar dos hipótesis: la nula, o primaria, H_0 y la alternativa H_a . Tras determinar un test apropiado, T , para el contraste, se calcula el p-valor, la medida de discrepancia, como la probabilidad de obtener un resultado más extremo del test que el obtenido con los datos observados.

$$p - \text{valor} = \mathbb{P} \{T(Y) \text{ sea más "extremo" que } T(Y_{obs}) \mid H_0\},$$

entendiendo como más “extremo” aquello que se acerca más a la hipótesis alternativa. Si el p-valor es más pequeño que una cota fijada previamente, se rechaza la hipótesis nula; si no, no se rechaza.

Este planteamiento presenta tres grandes problemas: solo se puede plantear con hipótesis que sean anidadas, es decir que una sea simplificación de la otra ¹, o contrapuestas; el contraste solo es capaz de proporcionar evidencia en contra de la hipótesis nula, en ningún caso acepta H_0 , fracasa a la hora de rechazarla; y el p-valor realmente no se corresponde con una medida de evidencia, sino más bien una probabilidad predictiva de observar en hipotéticas repeticiones del experimento valores más inusuales. Otra crítica más filosófica a los p-valores es que también dependen de la probabilidad de muestreo de valores no observados. Esto provoca que dos experimentos con verosimilitudes iguales presenten p-valores distintos si los experimentos se han diseñado de manera diferente. Berger y Wolper en su libro *The Likelihood Principle* [3] muestran este hecho como una violación del Principio de Verosimilitud:

Principio de Verosimilitud: Dado un modelo estadístico, toda la información relevante de una muestra respecto a los parámetros se encuentra contenida en la función de verosimilitud.

El enfoque Bayesiano es más simple y evita estos cuatro problemas. Haciendo uso de la noción de probabilidad subjetiva, se puede calcular la distribución posterior de los datos observados bajo las distintas hipótesis para compararlas. Al contrario que en el contraste Frecuentista, aquí se trabaja con modelos, no con hipótesis, y pueden compararse más de dos modelos sin necesidad de estar relacionados de alguna forma.

Por simplicidad explicaremos solo el contraste entre dos modelos M_1 y M_2 . Las distribuciones marginales de Y se pueden calcular haciendo variar los parámetros,

$$p(y|M_i) = \int p(y|M_i, \theta_i) p(\theta_i) d\theta_i \quad \text{para } i = 1, 2.$$

Y aplicando el Teorema de Bayes podemos obtener $\mathbb{P}(M_i|y)$. Para la comparación el Factor de Bayes (BF) es la magnitud más usada:

$$BF = \frac{p(M_1|y)/p(M_2|y)}{\mathbb{P}(M_1)/\mathbb{P}(M_2)} = \frac{\left[\frac{p(y|M_1)\mathbb{P}(M_1)}{p(y)} \right] / \left[\frac{p(y|M_2)\mathbb{P}(M_2)}{p(y)} \right]}{\mathbb{P}(M_1)/\mathbb{P}(M_2)} = \frac{p(y|M_1)}{p(y|M_2)}.$$

Asumiendo que ambos modelos son a priori igualmente probables, esto es $\mathbb{P}(M_1) = \mathbb{P}(M_2)$, se describe el Factor de Bayes como el ratio de ambas distribuciones marginales

$$BF = \frac{\mathbb{P}(M_1|y)}{\mathbb{P}(M_2|y)}.$$

¹Un ejemplo de esto sería que la hipótesis alternativa asignara a un parámetro del modelo un valor constante, usualmente cero.

Por otro lado, si asumimos que ambos modelos comparten parametrización $\theta_1 = \theta_2 = \theta$ y un contraste simple, $M1 : \theta = \theta^{(1)}$ y $M2 : \theta = \theta^{(2)}$, entonces el Factor de Bayes es el cociente de las verosimilitudes de los modelos

$$BF = \frac{p(y|\theta^{(1)})}{p(y|\theta^{(2)})}.$$

Por tanto, cuando se enfrentan dos alternativas, el Factor de Bayes no es más que los odds a favor de M_1 sobre M_2 teniendo en cuenta únicamente los datos observados.

Nótese que el Factor de Bayes depende también de las prior de los parámetros θ_i y, por tanto, de los posibles problemas de elicitación. Esto nos hace preguntarnos si existe alguna forma de eludir las prior. Una respuesta a este problema es el Método de Schwartz [26] (ΔBIC , *Bayesian Information Criterion*) que, para muestras de gran tamaño, n , es una aproximación de $-2\log(BF)$ y viene dado por:

$$\Delta BIC = W - (p_2 - p_1) \log(n) \quad \text{donde } W = -\log \left[\frac{\max_{M_1} p(y|\theta)}{\max_{M_2} p(y|\theta)} \right].$$

Aquí p_i es el número de parámetros del modelo M_i y W es el cociente de verosimilitudes. El segundo término actúa como un “regulador de tamaños” de los modelos, para ver esto basta con pensar en M_2 como un modelo completo y M_1 como una simplificación de este, por ello $\exp \left\{ -\frac{1}{2} \Delta BIC \right\}$ actúa como una aproximación del BF que es independiente de las distribuciones prior.

Existen otros métodos de ratio de verosimilitud penalizada como el Criterio de Akaike (ΔAIC , *Akaike Information Criterion*),

$$\Delta AIC = W - 2(p_2 - p_1).$$

Este método deriva de consideraciones frecuentistas sobre la eficiencia asintótica, donde n y p_i se acercan a infinito. Es muy popular este estadístico, pero solo converge asintóticamente a $-2\log(BF)$ si las distribuciones prior van a infinito con el mismo orden que la verosimilitud, una suposición muy poco práctica.

Aparte de estos estadísticos, existen muchos otros defendidos por varios autores; sin embargo, la búsqueda de estadísticos de contraste Bayesianos continúa siendo objeto de estudio.

2.1.5. Modelos Jerárquicos

La estructura Bayesiana consiste en asignar distribuciones a los parámetros; al hacer esto, construimos lo que se llama un modelo Bayesiano de dos niveles. Mientras que en estadística Frecuentista la función de verosimilitud, $p(x|\theta)$ es una función a maximizar para obtener un estimador, en Bayesiano se considera como una distribución. Por tanto, al considerar un modelo jerárquico de dos niveles, la verosimilitud depende de los hiperparámetros ν :

$$p(x|\nu) = \int p(x|\theta)p(\theta|\nu)d\theta$$

Si extendemos esta estructura a varios, digamos l , niveles, construimos un modelo jerárquico cuya verosimilitud acoge la forma:

$$p(x|\nu) = \int p(x|\theta_1)p(\theta_1|\theta_2) \dots p(\theta_l|\nu)d\theta_1 \dots d\theta_l$$

Notar que en ambos casos ν está determinado, si este también fuera un valor aleatorio sería necesario hacer variar su valor trabajando de esta forma con un modelo de tres y $l + 1$ niveles respectivamente:

$$p(x) = \int p(x|\theta)p(\theta|\nu)p(\nu)d\theta d\nu$$

$$p(x) = \int p(x|\theta_1)p(\theta_1|\theta_2)\dots p(\theta_l|\nu)p(\nu)d\theta_1\dots d\theta_l d\nu$$

Trabajar con modelos de varios niveles a primera vista parece mejor, ya que al incluir un mayor número de variables aporta más información y permite un mayor ajuste del modelo a los datos observados; pero esto también conlleva problemas de sobreajuste, derivando en predicciones erróneas del modelo. Por tanto, es conveniente hacer un balance entre ajuste y complejidad del modelo.

Para la elección del mejor modelo se usan distintos criterios puesto que el cálculo del BF es inviable en muchos modelos jerárquicos complejos. Uno de los más usados es el DIC (Deviance Information Criterion), propuesto por Spiegelhalter et al. [27]. El DIC es una variación del ΔAIC la cual se basa en la distribución posterior del estadístico *deviance*:

$$D(\theta) = -2 \log(p(y|\theta)) + C$$

Donde C es una constante irrelevante para la comparación. Con este criterio se mide el ajuste del modelo a los datos con la esperanza de D , $\bar{D} = E_{\theta|y}[D(\theta)]$ y su complejidad con el número de parámetros efectivos:

$$p_D = \bar{D} - D(\bar{\theta}), \quad \text{siendo } \bar{\theta} = E[\theta].$$

Así se define $DIC = \bar{D} + p_D = 2\bar{D} - D(\bar{\theta})$, indicando los valores pequeños un mejor ajuste y menor complejidad.

2.1.6. Métodos de estimación

La inferencia Bayesiana se basa en la distribución posterior de los datos. Debido a la complejidad del cálculo necesario no siempre se obtiene una distribución posterior cerrada; por ello, son necesarios varios métodos de estimación.

En casos simples, haciendo uso de los prior conjugadas, se pueden usar métodos analíticos, ya que la expresión final suele ser sencilla; aunque para modelos más complejos no suele ser aplicable este método. Cuando la expresión de la distribución posterior es demasiado compleja como para tratarla analíticamente, se usan métodos numéricos o de simulación. El método más usado en estos casos son las Cadenas de Markov de Monte Carlo (MCMC) seguido por la aproximación INLA (Integrated Nested Laplace Approximation).

Los algoritmos MCMC permiten obtener distintas simulaciones de muestras haciendo uso de Cadenas de Markov con las que calcular distintas aproximaciones de la distribución posterior. Este método es muy flexible y es aplicable a la gran mayoría de los casos, pero puede ser computacionalmente muy costoso y requiere de un análisis riguroso de la convergencia. Un ejemplo de su flexibilidad es el algoritmo Gibbs Sampling [14], se aplica en situaciones donde la distribución posterior completa es demasiado compleja como para obtener un muestreo para el MCMC, pero las distribuciones condicionadas son más manejables. El algoritmo consiste en obtener las muestras del parámetro θ_i de $p(\theta_i|\theta_{-i}, y)$ en vez de la distribución posterior completa.

Por otro lado, INLA está diseñado específicamente para modelos latentes gaussianos jerárquicos. Los modelos latentes gaussianos son modelos donde las variables latentes, γ , es decir, las variables no observadas, forman un campo gaussiano, es decir, cualquier subconjunto finito de parámetros tiene una distribución normal multivariante conjunta. Estos modelos suelen presentar una dimensionalidad alta, por lo que MCMC es costoso de aplicar, además de presentar distribuciones que no son posibles de integrar directamente. INLA consiste en la aplicación de Laplace para obtener las distribuciones $p(\gamma|\theta, x)$ y $p(\theta|x)$ para después calcular de manera numérica:

$$p(\gamma_i | x) = \int p(\gamma_i | \theta, x) p(\theta | x) d\theta$$

Para este trabajo usaremos el método de MCMC. Durante este proceso se simulan m cadenas distintas de n iteraciones cada una; el objetivo de este algoritmo es encontrar la convergencia de la distribución posterior del modelo en cuestión. Cada cadena comienza con condiciones iniciales distintas; por ello, se suelen desechar las l primeras iteraciones de las cadenas para así evitar que las condiciones iniciales afecten al estudio de la convergencia. Muchos autores proponen un número distinto de iteraciones; nosotros seguiremos la recomendación de Gelman y Rubin [13]; desechar la mitad de las iteraciones, es decir, $n = 2l$. Para comprobar la fiabilidad de los resultados tendremos que realizar un diagnóstico de convergencia que consistirá en verificar que coincidan los límites de las distintas cadenas y la independencia de las muestras simuladas mediante la función de autocorrelación (*ACF*) de los parámetros. Para la última verificación bastará con comprobar gráficamente que la autocorrelación tiende a 0 mientras que para la independencia de las simulaciones y la convergencia de las cadenas necesitaremos el uso de estadísticos, estos serán el estadístico de Gelman-Rubin y el ESS (Effective Sample Size). El estadístico de Gelman-Rubin, R , es una comparación entre la varianza de las medias de las cadenas, $\frac{B}{l}$ y la media de las varianzas individuales de cada cadena, W . Su estimación viene descrita por:

$$\sqrt{\hat{R}} = \sqrt{\left(\frac{l-1}{l} + \frac{m+1}{ml} \frac{B}{M} \right) \frac{df}{df-2}}$$

Conforme $n \rightarrow +\infty$ debería converger a 1, como esto es un método numérico, se suele considerar como cota aceptable 1,05. Cuando el estadístico sobrepasa el límite, se considera que las cadenas tienen distintos límites.

Por otro lado, el ESS sirve para estudiar la independencia entre las simulaciones y viene descrito por:

$$ESS = \frac{l}{1 + 2 \sum_{k=1}^{+\infty} \rho_k(\lambda)}$$

Siendo $\rho_k(\lambda)$ la autocorrelación del parámetro de interés λ en un lag de longitud k de la cadena, es decir, entre las iteraciones de la cadena de la forma j y $j + k$.

Lo ideal es que el estadístico sea superior a 1000, aunque en la práctica se suele considerar aceptable cuando es superior a 100. Aunque autores como Gelman recalcan que el valor de ESS ha de ser elevado [12], el umbral de 100 no es una regla numérica. Se popularizó cuando herramientas como BUGS o JAGS implementaron este umbral. Esta elección se asienta en el error estándar de una media calculada con MCMC:

$$MCSE \approx \frac{\sigma}{\sqrt{ESS}}$$

Aquí σ es la varianza de la posterior del estimador que se calcula. Cuando $ESS = 100$ el error cometido por MCMC es aproximadamente el 10 % de la desviación estándar, mientras que si $ESS = 1000$ este ronda el 3 %.

Posteriormente Vehtari et al. [30] mostraron la problemática de tener un único ESS para estudiar la convergencia global, ya que la convergencia en el centro y en las colas no acostumbra a coincidir. Introdujeron ESS_{bulk} y ESS_{tail} como los ESS del centro y de las colas respectivamente. ESS_{bulk} al representar la convergencia en el centro nos informa sobre el comportamiento de las medias y las medianas, mientras que ESS_{tail} está relacionado con los valores en los extremos de la distribución, altos como los quantiles $Q_{0,95}$ o $Q_{0,99}$ y bajos como $Q_{0,05}$ o $Q_{0,01}$.

Con todo esto podemos comprobar que el algoritmo MCMC se ha aplicado correctamente.

2.2. Cadenas de Markov

La teoría explicada en este apartado se puede encontrar en los manuales Markov Chains de J.R. Norris [23] y Markov Chains: Gibbs Fields, Monte Carlo Simulation and Queues de P. Brémaud [5].

Las Cadenas de Markov constituyen una de las herramientas estadísticas fundamentales para el estudio de procesos estocásticos. Un proceso estocástico, de manera matemática, se define como una colección de variables aleatorias $X = (X_t)_{t \geq 0}$ que comparten un mismo espacio de probabilidad. Atendiendo al conjunto de índices en la colección, al que llamaremos tiempo, podemos distinguir entre procesos discretos cuando la colección es numerable, $(X_n)_{n \in \mathbb{N}}$, o continuos cuando no lo es, $(X_t)_{t \in \mathbb{R}^+}$. Además, cuando el codominio de las variables aleatorias $\mathcal{I}$, a cuyos elementos llamamos estados, es un subconjunto de $\mathbb{N}$ llamamos al proceso cadena, y cuando la cadena satisface la Propiedad de Markov la llamamos Cadena de Markov. En el caso continuo la Propiedad de Markov se describe como:

Propiedad de Markov. Sea $(X_t)_{t \geq 0}$ una Cadena de Markov. Dado $j \in \mathcal{I}$ tenemos que

$$\mathbb{P}(X_{t+s} = j | \mathcal{F}_t) = \mathbb{P}(X_{t+s} = j | X_t) = p_{X_t, j}(t, t+s) \quad \forall t, s \geq 0$$

Donde $\mathcal{F}_t = \sigma(\{X_l | 0 \leq l \leq t\})$ es la sigma-álgebra generada por las variables previas al momento t . Esta propiedad se traduce en que la relevancia del proceso para que ocurra algo en un momento se reduce al instante previo a este. Además, decimos que la cadena es homogénea si satisface $\mathbb{P}(X_{t+s} = j | X_t) = \mathbb{P}_{X_t}(X_s = j) = p_{i, j}(s)$, es decir, la probabilidad de un suceso condicionado al proceso previo solo depende del tiempo transcurrido, no del momento en el que ocurre.

Gracias a esto, para describir el comportamiento de una Cadena de Markov homogénea, solo necesitamos dos elementos: la distribución inicial λ de la variable X_0 y la matriz estocástica $P(t) = (p_{i, j}(t))_{i, j \in \mathcal{I}}$. Denotamos esto como $X \sim HMC(\lambda, P(t))$.

Para este modelo trabajaremos con una Cadena de Markov continua y homogénea de tiempo continuo. En estos casos la matriz estocástica puede definirse como $P(t) = e^{tQ}$ donde $Q = (q_{i, j})_{i, j \in \mathcal{I}}$ es una Q -matriz, es decir una matriz que satisface $q_{i, j} \geq 0$ para todo $i \neq j \in \mathcal{I}$ y $\sum_{k \in \mathcal{I}} q_{i, k} = 0$ para todo $i \in \mathcal{I}$. Lo que hace a esta matriz Q especial no es solo su consecuente simplificación de los cálculos de $P(t)$ sino también su interpretación que se explica más adelante con la Propiedad de Markov Fuerte.

Cuando trabajamos con procesos, por simplificación, exigimos por definición que sean *càdlàg*, es decir, que sus trayectorias sean continuas por la derecha y con límites por la izquierda, para así poder caracterizar los procesos por familias de distribución finitas. Esto nos permite definir los siguientes tiempos aleatorios:

- Tiempos de salto: $J_0, \dots, J_n$

$$\begin{cases} J_0 = 0 \\ J_{n+1} = \inf (t \geq J_{n-1} | X_t \neq X_{J_n}) \end{cases}$$

- Tiempo de espera: $S_1, \dots, S_n$

$$S_n = \begin{cases} J_n - J_{n-1} & \text{si } J_{n-1} < +\infty \\ +\infty & \text{si } J_{n-1} = +\infty \end{cases}$$

Una aplicación muy útil de estos tiempos es la discretización del proceso considerando solo los momentos en los que el proceso cambia de estado, definiendo así la cadena incorporada, o cadena de saltos, Y al proceso X :

$$(Y_n)_{n \geq 0} = (X_{J_n})_{n \geq 0}$$

Otro concepto clave para este modelo son los tiempos de parada. Decimos que un tiempo aleatorio T es un tiempo de parada del proceso X si $\{T \leq t\} \in \mathcal{F}_t$, en otras palabras, T es un tiempo de parada si para saber si ocurre en el momento t basta con conocer el proceso hasta ese momento. Un ejemplo sencillo con el que ilustrar esta idea son los tiempos de salto, ya que es sencillo ver que $\{J_k \leq t\} \in \mathcal{F}_t$ para todo k .

Una consecuencia directa de esta definición es la **Propiedad de Markov Fuerte (PMF)**. Esta es una extensión de la Propiedad de Markov que nos permite cambiar el momento de referencia a un tiempo aleatorio. De esta forma cada vez que el proceso llega a un tiempo de parada reinicia el proceso.

Propiedad de Markov Fuerte. Sea $(X_t)_{t \geq 0} \sim MC(\lambda, Q)$. Si $\mathcal{T}$ es un tiempo de parada, condicionando a $\mathcal{T} < \infty$ y $X_{\mathcal{T}} = i \in \mathcal{I}$, tenemos que

$$(X_{\mathcal{T}+s})_{s \geq 0} \sim MC(\delta_i, Q)$$

Donde $\delta_i = (\delta_{i,j})$ es la delta de Kronecker, $\delta_{i,i} = 1$ y $\delta_{i,j} = 0 \forall j \neq i$.

Así pues, al aplicar esta propiedad a un proceso condicionado a $X_0 = i$ y siendo $Q = (q_{i,j})_{i,j \in \mathbb{I}}$ la Q-matriz asociada, obtenemos que:

- $\mathbb{P}_i(X_{J_1} = j) = \frac{q_{i,j}}{-q_{i,i}}, \quad j \neq i$
- $S_1 \sim \text{Exp}(-q_{i,i})$

Estos resultados permiten interpretar las entradas de la Q-matriz. En primer lugar, el valor $-q_{i,i}$ representa la tasa de salida del estado i , de modo que el tiempo de permanencia en dicho estado sigue una distribución exponencial de parámetro $-q_{i,i}$, y por tanto su esperanza es $1/(-q_{i,i})$.

Por otro lado, para $j \neq i$, los coeficientes $q_{i,j}$ representan las intensidades de transición desde el estado i al estado j . En particular, la probabilidad de que el próximo salto desde i tenga como destino el estado j viene dada por

$$\mathbb{P}_i(X_{J_1} = j) = \frac{q_{ij}}{-q_{ii}}.$$

Así pues, teniendo en cuenta la PMF y que los tiempos de salto son tiempos de parada, podemos extender estas distribuciones a todo el proceso.

Otro resultado importante que necesitaremos es el siguiente teorema.

Teorema 2.2.1. *Dado un proceso de conteo, es decir, un proceso $X = \{X_t\}_{t \geq 0}$ tal que $X_0 = 0$ y $X_t - X_{t-} \in \{0, 1\}$, tenemos las siguientes equivalencias:*

- **Definición de la cadena de saltos y tiempos de espera:** $(Y_n, S_{n+1})_{n \geq 0}$ satisfacen $Y_n = n$ y $S_n \sim \text{Exp}(\mu)$ siendo S_n iid.
- **Definición de comportamiento infinitesimal:** Los incrementos son variables aleatorias independientes y para $h > 0$ y uniformemente en t tenemos que

$$\begin{cases} \mathbb{P}(X_{t+h} - X_t = 0) = 1 - \mu h + o(h) \\ \mathbb{P}(X_{t+h} - X_t = 1) = \mu h + o(h) \\ \mathbb{P}(X_{t+h} - X_t > 1) = o(h) \end{cases}$$

Aquí $o(h)$ es una función de orden menor que h , $\lim_{h \rightarrow 0} \frac{o(h)}{h} = 0$.

- **Definición de probabilidad de transición:** X tiene incrementos independientes y estacionarios y $X_t \sim \text{Po}(\mu t)$

Gracias a este teorema, bajo las mismas condiciones y asumiendo que $X_{t+s} - X_s = 1$, tenemos que

$$J_{X_s+1} \sim \mathcal{U}(s, t+s)$$

Esto, al considerar un proceso que contabiliza los saltos de otra cadena, nos permite calcular la probabilidad de que se produzca un cambio de estado en esta.

Volviendo al objetivo principal del estudio, podemos modelizar la visibilidad del tumor por imagen como una variable aleatoria binaria

$$\mathcal{C}(t) = \begin{cases} 1 & \text{si hay tumor en el momento } t \\ 0 & \text{si no hay tumor en el momento } t \end{cases}$$

De esta forma podemos extender esta variable de forma natural para cada paciente i a una Cadena de Markov de tiempo continuo $(C_{i,t})_{t \in \mathbb{N}}$ considerando los días desde el comienzo del seguimiento como el tiempo.

Por tanto, considerando esta modelización, nuestro objetivo será encontrar el momento en el que el tumor es visible, es decir, cuando la cadena cambia al estado 1. Si definimos

$$\tau_i = \inf\{t \geq 0 \mid \text{el tumor del paciente } i \text{ es visible por imagen}\},$$

es fácilmente identificable como un tiempo de parada ya que si el proceso comienza con $X_0 = 0$ se identifica con J_1 , el cuál sabemos que es un tiempo de parada.

2.3. Análisis de Supervivencia

La segunda herramienta de la que haremos uso es el Análisis de Supervivencia, cuyo objetivo es modelizar el tiempo que transcurre hasta un suceso. En los estudios longitudinales se establece una fecha inicial y final de la recogida de datos y es habitual que algunos perfiles a los cuales se les ha hecho el seguimiento no experimenten el suceso o que se pierda el rastro de algunos durante este periodo. Antes se desechaban estos datos, provocando una gran pérdida de información útil para el estudio, pero con la introducción de la censura se consiguió incorporar la máxima información posible de este tipo de datos.

Llamamos datos censurados a aquellos que o bien están incompletos, es decir, los perfiles no han completado el periodo de seguimiento, o bien no ha ocurrido el suceso. Aunque este tipo de datos parecen no ser útiles, aportan información parcial al estudio y el Análisis de Supervivencia está explícitamente diseñado para aprovechar esta información. Es cierto que no se tiene registrado el momento en que ocurre el suceso censurado, pero sí sabemos que el evento no ha aparecido durante el seguimiento. Los elementos matemáticos propios de este tipo de análisis son:

- La *función de supervivencia*

$$S(t) = \mathbb{P}(T > t) = 1 - \mathbb{P}(T \leq t)$$

Donde T es el tiempo aleatorio en el que ocurre el suceso, es decir marca la probabilidad de “sobrevivir” t tiempo.

- El *hazard* o riesgo

$$\delta = \lim_{\epsilon \rightarrow 0} \frac{\mathbb{P}(T > t + \epsilon | T > t)}{\epsilon}$$

que marca la probabilidad de estar vivo en los próximos instantes dado que estas vivo ahora.

En la práctica hay distintos métodos para aproximar la función de supervivencia pero los más usados son tres:

- **Método Kaplan-Meier.** Este es un método no paramétrico que únicamente necesita de los datos recogidos para construir de manera directa $S(t)$, calculando la probabilidad de experimentar el suceso en cada intervalo de tiempo; de esta forma, no es necesaria hacer ninguna suposición sobre los datos. Este método resulta en una función escalonada que, aunque es fiel a los datos recogidos, no se comporta bien con las variables continuas y tampoco es capaz de recoger el efecto de varios factores simultáneamente.
- **Método Exponencial.** Este método asume que el comportamiento de la función de supervivencia es exponencial, por lo que es un método paramétrico. De esta forma resultas en una función de supervivencia de la forma $S(t) = e^{-\lambda t}$ siendo λ la tasa de riesgo, i.e $h(t) = \lambda$. Este método es muy útil para situaciones donde el riesgo no depende del tiempo, pero en ámbitos biológicos como el que tratamos, estos casos no son los más comunes.

- **Método de Cox.** A diferencia de los otros métodos este método es capaz de tener en cuenta el efecto de distintos factores que afectan al riesgo considerando la siguiente función de hazard

$$h(t, X) = h_0(t) \sum_i \beta_i X_i$$

Donde $h_0(t)$ representa el riesgo base y X los factores que lo afectan. Es un método semiparamétrico ya que al aplicarse no es necesario conocer de antemano la forma de la función base h_0 .

Nuestro interés en el análisis de supervivencia reside en el hazard, ya que usaremos este como ratio de tiempo para pasar del estado 0 al estado 1 en la cadena descrita en el subapartado anterior.

Capítulo 3

Metodología

Una vez explicadas la metodología Bayesiana y las herramientas estadísticas necesarias, ya podemos hablar sobre el objetivo principal de este trabajo: la aplicación y evaluación de un modelo Bayesiano capaz de predecir la aparición del tumor de cáncer colorrectal a partir del nivel de ADN tumoral circulante antes de ser visible por imagen. Para ello nos basamos en un modelo desarrollado por Amorós et al. para un estudio del biomarcador GALAD como predictor del carcinoma hepatocelular [2].

3.0.1. Notación

En este apartado se introduce la notación que usaremos para construir el modelo.

Llamaremos tomas a los análisis de sangre realizados durante el seguimiento a los pacientes.

Denotaremos por N_p al número de pacientes e indexaremos a cada paciente como $i \in \{1, \dots, N_p\}$, además, denotaremos como J_i al número de tomas efectuadas al paciente i , a cada una de estas la indexamos como $j \in \{1, \dots, J_i\}$.

También conviene asignar una notación al tiempo en días transcurridos entre el comienzo del seguimiento y cada toma, le asignaremos $t_{i,j}$, de esta forma, $t_{i,1} = 0 \forall i$.

3.1. Datos Clínicos

Los datos tratados en este trabajo han sido recolectados y gestionados por el Instituto de Investigación Sanitaria del Hospital Clínico de Valencia INCLIVA que posteriormente nos ha cedido para poder realizar este estudio. Trabajamos con datos de 45 pacientes adultos con cáncer de colon en estadio II-III confirmado histológicamente, postoperatorios, con ADN tumoral circulante positivo cuyo seguimiento ha sido gestionado por el Hospital Clínico de València. Durante este seguimiento a los pacientes han recibido el tratamiento FLOFOXIRI, principal régimen de quimioterapia intensiva aplicado en estos casos, y se les ha realizado un análisis de sangre y un tac cada 3 meses aproximadamente.

Para el seguimiento del biomarcador se han tomado como referencia las recomendaciones del estudio sobre el ctDNA de Dasari et al. [6]. Mediante el análisis de sangre se han monitorizado los niveles de las 4 variantes que presentan un mayor nivel de VAF por cada paciente. La metodología para la selección de estos genes se asienta en un ensayo académico basado en la secuenciación de amplicones mediante


NGS. Así pues, el nivel de VAF es el porcentaje de genes mutados de esta variante detectados en la biopsia.

Entre los 45 pacientes se ha analizado un total de 117 variantes mutadas de 22 genes distintos. Cabe resaltar que de estas variantes se han seguido 44 variantes del gen APC y 25 de TP53, ambos genes se han demostrado que son de gran utilidad para predecir el nivel de VAF en casos de tumor de CRC [28]. Dependiendo de la evidencia de varios estudios sobre si las variantes son causas de la aparición de CRC o no se han clasificado como: patogénicas, probablemente patogénicas, de significado incierto, probablemente benignas y benignas. Acorde a esta planificación, se han recolectado muestras de variantes que no son clasificadas como benignas y de variantes que, a falta de estudios, no se han clasificado en ninguna de estas categorías. Estas variantes se califican como (-).

Con el objetivo de simplificar el modelo y ajustarnos al tamaño de nuestra base de datos se han reagrupado las distintas variantes como:

- **Patogénicas:** variantes patogénicas y probablemente patogénicas.
- **Significado desconocido:** variantes clasificadas como significado incierto y variantes no clasificadas, (-).
- **No patogénicas:** variantes probablemente benignas.

(-)	50		
likely_benign	1	Patogénicas	65
likely_pathogenic	13	Significado desconocido	51
pathogenic	52	No patogénicas	1
uncertain_significance	1		



Es importante recalcar que, atendiendo a estas clasificaciones, únicamente contamos con una variante no patogénica, lo cual no permite desarrollar un modelo fiable que compare correctamente el desarrollo

de un paciente con este tipo de variante. Esto junto a la falta de evidencia de las variantes de significado desconocido nos lleva a estudiar únicamente las variables patogénicas.

Por otro lado, el seguimiento de los pacientes se ha controlado por distintos centros y, debido a problemas administrativos, varios resultados de TAC no han podido contabilizarse. Debido a esto, nuestra base de datos cuenta con solo tres pacientes que han desarrollado un tumor durante el seguimiento y en total contamos con cuatro mediciones de VAF de pacientes con cáncer clínico.




Figura 3.1: Aquí mostramos el diagnóstico realizado por imagen a los pacientes dados por el INCLIVA. A la izquierda se puede observar cuándo se diagnostican a los pacientes atendiendo al tiempo relativo dentro de cada seguimiento, mientras que a la izquierda se puede ver teniendo en cuenta los días pasados desde el comienzo del seguimiento. Además, en esta gráfica están marcados en el eje x los días aproximados en los que se han realizado las tomas a los pacientes.

3.2. Modelo para la detección del tumor mediante VAF

Desarrollamos un modelo jerárquico de cadenas ocultas de Markov que represente el desarrollo de la enfermedad. Para ello se han considerado las siguientes asunciones:

1. El crecimiento de niveles de los VAF de variantes patógenas implica el desarrollo del tumor.
2. No hay falsos positivos en el diagnóstico.
3. Es distinto ser diagnosticado de tener un tumor formado, puesto que el tumor aparece antes de su diagnóstico.

En la figura 3.2 se muestra un grafo que resume el funcionamiento del modelo y muestra las dependencias entre las variables y los parámetros. En los siguientes apartados se explican detalladamente los niveles del modelo.




Figura 3.2: Este diagrama explica el funcionamiento del modelo. Los distintos colores se refieren a los diferentes niveles de este, siendo azul el nivel de VAF, verde la media del nivel de VAF, rojo el desarrollo oculto del CRC y amarillo el relativo al diagnóstico. Los nodos redondos referencian a variables, siendo las de borde grueso las observadas y las de borde fino las latentes, mientras que los nodos cuadrados referencian a los hiperparámetros.

Niveles de VAF

Como hemos explicado previamente, durante el seguimiento se realizan mediciones mediante biopsia líquida del VAF de cada paciente. El VAF es la proporción de lecturas de un gen que muestra una mutación.

Debido a la reducida cantidad de datos y a la falta de un score viable para este caso, consideramos como predictor la suma de los porcentajes de las variantes. Esto no es lo más idóneo ya que perdemos información sobre el aporte individual de cada variante al desarrollo de la enfermedad. Si trabajásemos con una mayor base de datos, podría considerarse algún tipo de combinación de los niveles donde cada variante tiene un peso asignado, mostrando ese aporte individual al ERM que obviamos con este enfoque.

Así pues, el nivel $V_{i,j}$ de cada toma j de cada paciente i sigue una distribución normal de media $\mu_{i,j}$ y desviación típica σ .

$$V_{i,j} \mid \mu_{i,j}, \sigma^2 \sim \mathcal{N}(\mu_{i,j}, \sigma^2)$$

La desviación típica de cada toma no varía, mientras que la media depende del paciente y de la toma. El valor de la media depende de varios factores, de entre los cuales el principal es si el paciente ha desarrollado un tumor o no:

$$\mu_{i,j} = \nu + b_i + C_{i,j}\beta(t_{i,j} - \tau_i) \quad \text{donde} \quad b_i \mid \sigma_b^2 \sim \mathcal{N}(0, \sigma_b^2)$$

Aquí la variable ν representa el nivel basal genérico de VAF poblacional y b_i el factor propio de cada paciente, ya que hay algunos pacientes que, por genética, son más o menos proclives a presentar mayores o menores niveles de VAF. Por otro lado, $C_{i,j}$ es el valor de la cadena de Markov oculta del paciente que toma como valores 1 o 0 dependiendo de si el paciente i presenta un tumor desarrollado en la toma j o no, de tal forma que $C_{i,j} = \mathbb{I}_{\{t_{i,j} > \tau_i\}}$ donde τ_i representa el momento en el que el paciente desarrolla el tumor y $t_{i,j}$ el tiempo transcurrido en días desde la primera toma. En el siguiente apartado se dan más detalles sobre esta cadena.

Con esta construcción se satisface la primera suposición, ya que el nivel de VAF del paciente i se mantiene estable hasta pasado el momento τ_i ; a partir de ahí, el nivel crece de manera lineal con un crecimiento β .

Desarrollo oculto del CRC

Para modelizar el desarrollo de la enfermedad consideramos un modelo de cadenas de Markov ocultas de tiempo continuo. Esta elección se debe a que, aunque el tumor vaya desarrollándose a diario, solo podemos observar su estado en determinados momentos, cuando se realiza un tac. Así pues para cada paciente se considera una cadena $C_i = \{C_{i,j}\}_{j \in 1, \dots, J_i}$ cuya matriz de probabilidad llamaremos $\Gamma_{i,j} = (\gamma_{a,b \mid i,j})_{a,b \in \{0,1\}}$ donde $\gamma_{a,b \mid i,j} = \mathbb{P}(C_{i,j+1} = b \mid C_{i,j} = a)$. Como hemos mencionado previamente, el desarrollo del tumor es continuo, mientras que nosotros solo podemos conocer el valor de la cadena cuando se realiza un tac; esto convierte el proceso en una cadena semiobservada. Además, no todas las tomas son equidistantes (por causas externas al seguimiento, en algunos casos se adelantan o retrasan las tomas); esto hace que $\Gamma_{i,j}$ dependa de $\Delta t_{i,j+1} = t_{i,j+1} - t_{i,j}$. Por tanto consideramos:

$$\Gamma_{i,j} = \exp(\Delta t_{i,j+1} A_i) \quad \text{donde } A_i = \begin{pmatrix} -\lambda_i & \lambda_i \\ 0 & 0 \end{pmatrix}$$

Aquí la variable $\lambda_i > 0$ es el hazard de desarrollar el tumor. De esta forma:

$$\Gamma_{i,j} = \begin{pmatrix} e^{-\Delta t_{i,j+1} \lambda_i} & 1 - e^{-\Delta t_{i,j+1} \lambda_i} \\ 0 & 1 \end{pmatrix}$$

A su vez, consideraremos el hazard como una combinación log-lineal de la predisposición genética de cada paciente, es decir

$$\log(\lambda_i) = \zeta + b_i \xi \quad (3.1)$$

Remarcamos que en este nivel del modelo es donde se juntan ambas herramientas estadísticas explicadas en los apartados anteriores. Aplicamos el concepto de hazard, λ_i estimado usando el método de Cox con el factor individual de cada paciente como covariable, proveniente del análisis de supervivencia a la Q-matriz, $A_{i,j}$ que describe la cadena de Markov.

Como mencionábamos en el apartado anterior, $\tau_i = \inf \{t_{i,j} : C_{i,j} = 0, C_{i,j+1} = 1\}$ lo que constituye un tiempo de parada, lo que le otorga propiedades idóneas para su estimación. Por ejemplo, notar que el τ_i viene descrito de forma discreta mientras que estamos interesados en su descripción continua, para ello usamos un resultado teórico que, bajo estas condiciones:

$$\tau_i \sim \mathcal{U}(t0_i, t1_i) \quad \text{donde } \begin{cases} t0_i = t_{i,j} & \text{tal que } C_{i,j} = 0, C_{i,j+1} = 1 \\ t1_i = t_{i,j+1} & \text{tal que } C_{i,j} = 0, C_{i,j+1} = 1 \end{cases}$$

Con esta construcción conseguimos que el modelo no dependa de los resultados observados sino del desarrollo subyacente del tumor.

Diagnóstico

Con la tercera suposición del modelo diferenciamos entre los pacientes que tienen un tumor desarrollado y localizado, es decir, han sido diagnosticados con CRC, y los que lo tienen desarrollado pero aún no se ha localizado por imagen.

Para que un diagnóstico por imagen sea fiable, debe haber pasado tiempo suficiente desde el comienzo de la duplicación de las células cancerosas ya que la sensibilidad del TAC para tumores de diámetro inferior a $5 - 10mm$ se encuentra entre el 50 % y el 70 % [21]. Por tanto cuanto más tiempo pase desde que se forma el tumor más sencillo es localizarlo. Para modelizar este suceso usaremos una variable Bernoulli cuyo parámetro dependerá de si el tumor está presente o no, es decir:

$$D_{i,j} \mid q_{C_{i,j} \ i,j} \sim Ber(q_{C_{i,j} \ i,j}) \quad q_{C_{i,j} \ i,j} = \begin{cases} 1 - e^{-\delta(t_{i,j} - \tau_i)} & \text{si } C_{i,j} = 1 \\ 0 & \text{si } C_{i,j} = 0 \end{cases}$$

De esta forma, la probabilidad de diagnosticar a un paciente cuando el tumor está presente se comporta como una exponencial de parámetro $\delta > 0$ y cuando un paciente no ha desarrollado el tumor todavía no es posible diagnosticarlo, satisfaciendo así la suposición 2 explicada en la sección 3.2.

Al modelizar el diagnóstico de esta forma, el modelo tiene en cuenta esta variable para calcular el valor de $C_{i,j}$, asumiendo que es posible contener pacientes no diagnosticados pero sí con tumor desarrollado

entre los datos de entrenamiento del modelo. Además, para la posterior predicción podemos omitir esta rama del modelo ya que no estamos interesados en cuándo el médico localizará el tumor sino en cuándo podrá ser visible por imagen.

Distribuciones prior de los hiperparámetros

Como se comenta en la introducción a la estadística Bayesiana, es necesario asignar a los parámetros distintas distribuciones prior que no condicionen el modelo de forma subjetiva. Para ello consideraremos las siguientes distribuciones:

$$\begin{aligned} \beta &\sim \mathcal{U}(0, h_\beta) & \sigma &\sim \mathcal{U}(0, h_\sigma) & \sigma_b &\sim \mathcal{U}(0, h_{\sigma_b}) \\ \nu &\sim \mathcal{N}(0, h_\nu) & \zeta &\sim \mathcal{U}(h_{\zeta 1}, h_{\zeta 2}) & \xi &\sim \mathcal{U}(h_{\xi 1}, h_{\xi 2}) & \delta &\sim \mathcal{U}(0, h_\delta) \end{aligned}$$

Para las desviaciones σ y σ_b hemos optado por una distribución uniforme como sugiere Gelman [12]. En cuanto a la variable ν , que representa el nivel basal poblacional de una variable normal, el nivel de ADN tumoral circulante se comporta como una distribución normal, optamos por una distribución normal ya que es conjugada de sí misma. Para el resto de parámetros usamos la distribución uniforme. Notar que los límites inferiores son 0 salvo para ζ y ξ ; si ambas variables se anulan a la vez, nos encontraríamos con $\log(\lambda_i) = 0$, lo cual carece de sentido en este caso.

Cabe resaltar que consideramos estas variables como independientes a priori; por tanto, cuando hablemos de la distribución prior conjunta, no será más que el producto de las prior individuales.

Distribución posterior conjunta

Los parámetros del modelo son $\Theta = \{\beta, \sigma^2, \sigma_b^2, \nu, \xi, \zeta, \delta\}$. También consideraremos las variables auxiliares relativas al sistema subyacente $\Psi = \{\mathbf{C}, \tau, b\}$, donde $\mathbf{C}$ es la cadena oculta del verdadero desarrollo del CRC, τ el momento de aparición del tumor (dependiente de $\mathbf{C}$) y b la predisposición aleatoria propia del paciente al desarrollo de la enfermedad. Con todo esto podemos definir la distribución posterior como:

$$p(\Theta, \Psi | \mathbf{V}, \mathbf{D}) \propto f(\mathbf{V}, \mathbf{D}, \Psi | \Theta) \pi(\Theta)$$

Donde $\mathbf{V}$ y $\mathbf{D}$ son el nivel de VAF y el diagnóstico, respectivamente, $f(\mathbf{V}, \mathbf{D}, \Psi | \Theta)$, la función de verosimilitud y $\pi(\Theta)$, las distribuciones prior de los parámetros del modelo definidas en el apartado anterior. Al considerar las variables como independientes, podemos escribir la verosimilitud como el producto de las verosimilitudes por separado.

$$f(\mathbf{V}, \mathbf{D}, \Psi | \Theta) = \prod_{i=1}^{N_p} f(\mathbf{V}_i | \Theta, \Psi) f(\mathbf{D}_i | \Theta, \Psi) \times f(\mathbf{C}_i | \lambda_i) f(\tau_i | \mathbf{C}_i) f(b_i | \sigma_b^2)$$

Donde recordamos que λ_i es una combinación exponencial descrita en la ecuación (3.1).

Puntualizamos que las variables $\mathbf{V}$ y $\mathbf{D}$, y por tanto sus funciones de verosimilitud, son las referentes a las observaciones del seguimiento mientras que la verosimilitud de las variables auxiliares es propia del avance semiobservado de la enfermedad.

3.3. Datos Sintéticos

Antes de comenzar el estudio, se mantuvo una reunión con el INCLIVA para ver los distintos estudios o proyectos pendientes de los que disponían para poder colaborar con ellos y acordamos tratar este tema. Posteriormente se fue desarrollando el modelo en base a una estructura y tamaño de los datos que, debido a los fallos administrativos, resultó no ser la esperada. Para cuando nos llegaron los datos, era demasiado tarde como para cambiar el enfoque del proyecto. Dado que el tamaño y la condición de los datos no permiten hacer una correcta estimación de los parámetros, hemos optado por aplicar el modelo a datos sintéticos para estudiar la capacidad de este para la recuperación de los parámetros según el tamaño y las características de los datos. Las consecuencias de la calidad de los datos se explican en la sección 4.1.1.

Para generar los datos sintéticos se han considerado los siguientes valores de los hiperparámetros:

$$\begin{aligned}\beta &= 0,2 & \sigma &= 2,5 & \sigma_b &= 0,5 & \nu &= 0,5 \\ \zeta &= -8 & \xi &= -2 & \delta &= 0,075 & \Gamma_0 &= 0,1\end{aligned}$$

Estos valores se han seleccionado con el objetivo de que se asemejen lo máximo posible a datos clínicos realistas. Varios estudios estiman que el HR de recaída de pacientes recuperados de CRC se encuentra entre 9 y 11 [32]. Dado que el riesgo sigue la ecuación 3.1, el hazard ratio entre dos pacientes con factores individuales b_1 y b_2 viene dado por

$$HR = \frac{\lambda_1}{\lambda_2} = \exp(\xi(b_1 - b_2)).$$

Notar que el parámetro ζ se cancela, lo que nos otorga libertad para escoger su valor. Guiándonos en las distribuciones posteriores obtenidas tras aplicar el modelo a los datos clínicos originales, que se pueden observar en la figura 4.1, consideramos $\zeta = -8$, un valor levemente más elevado que la media de la estimación para así contar en la muestra con más pacientes que desarrollen CRC sin alejarnos de los datos clínicos reales.

Por tanto, la variabilidad relativa del riesgo entre pacientes viene determinada únicamente por ξ . Si consideramos los valores $b_1 = 0,55$ y $b_2 = -0,55$, valores situados en los extremos de la distribución de b_i , con $\xi = -2$, obtenemos una diferencia de $b_1 - b_2 \approx 1,1$ lo que produce

$$HR = \exp(2,2) \approx 9,03,$$

valor compatible con los hazard ratios de recaída descritos en la literatura para pacientes recuperados de cáncer colorrectal.

Por otro lado, el valor de delta se corresponde con la media de la distribución posterior de su equivalente en el estudio sobre carcinoma hepatocelular de Amorós et al.[2], donde se propone el modelo usado en el presente estudio.

En cuanto a los valores del VAF, β , σ , σ_b y ν , nos hemos basado en los resultados de la estimación de parámetros del MCMC no convergente de los datos originales que, aunque no nos ofrezcan información verídica, nos sirven para orientarnos.

El valor de Γ_0 se traduce simplemente en cuántos pacientes comenzarán el seguimiento con cáncer desarrollado. Decidimos dejarlo en 10 % para así presentar una base de datos con un número reducido

de pacientes con tumor ya desarrollado; de esta forma, el modelo cuenta con información de la variación de VAF para que se pueda analizar correctamente el crecimiento cuando hay un tumor presente.

Se han creado dos conjuntos de datos, ambos con 40 pacientes, pero varían en la longitud del seguimiento, con seguimientos de 5 y 10 tomas equidistantes por 120 días. De esta forma, podemos analizar también la implementación del modelo atendiendo a la longitud temporal de los datos. Dado que las dos bases de datos se han creado con el mismo algoritmo, basta con mostrar el análisis descriptivo de solo uno de los conjuntos. Además, al ser sintéticos, contamos también con la información del desarrollo oculto de la enfermedad, lo cual nos permitirá evaluar la sensibilidad, especificidad y rapidez de la detección.

El segundo conjunto de datos son seguimientos que constan de 10 tomas a cada paciente. En este conjunto contamos con 5 de los 40 pacientes que comienzan el seguimiento con tumor presente, de los cuales solo 2 están correctamente diagnosticados, y el seguimiento finaliza con 18 pacientes con tumor y todos ellos correctamente diagnosticados. Durante este seguimiento solo hubo 5 falsos negativos, es decir, solo 5 diagnósticos erróneos, pero ningún tumor pasa desapercibido en dos tomas consecutivas.




Figura 3.3: En esta gráfica se muestran los niveles de VAF patógeno de 10 de los pacientes simulados. Los puntos en los seguimientos hacen referencia a las tomas donde se diagnostica el cáncer clínico, mientras que las cruces marcan el día donde realmente aparece el tumor.

Capítulo 4

Resultados

4.1. Inferencia y Predicción

En esta sección aplicamos el método MCMC sobre los distintos conjuntos de datos: los clínicos reales, mostrando las consecuencias de la estructura y calidad de los datos; y ambos bancos de datos sintéticos generados previamente. Tras realizar la inferencia, estudiaremos las distribuciones posteriores obtenidas para los parámetros con el objetivo de usarlas como prior para la posterior predicción realizada sobre un banco de datos sintéticos nuevo.

Evaluaremos el funcionamiento del modelo en términos de sensibilidad y rapidez de detección en comparación con el diagnóstico clínico.

4.1.1. Inferencia

Para la inferencia se ha usado el algoritmo MCMC obteniendo la distribución posterior sobre los parámetros y las variables auxiliares a partir del proceso observado. Para obtener la distribución prior de solo los parámetros Θ , es decir, $\pi(\Theta|\mathbf{V}, \mathbf{D})$, basta con considerar los valores simulados con MCMC ignorando las variables auxiliares. Sin embargo, este método nos permite obtener también las verosimilitudes de las variables auxiliares considerando los valores simulados.

Para llevar a cabo este proceso se ha usado la versión 1.4.1 del paquete `nimble` [9, 8] en RStudio con un procesador 11th Gen Intel(R) Core(TM) i5-1135G7 a 2.40 GHz.

Primero mostramos los resultados de aplicar el modelo a los datos clínicos reales. Este proceso ha tenido una duración de 76,5 seg.

Con el objetivo de mostrar objetividad, para las simulaciones hemos considerado las siguientes priors iniciales :

$$\begin{aligned} \beta &\sim \mathcal{U}(-3, 3) & \sigma &\sim \mathcal{U}(0, 10) & \sigma_b &\sim \mathcal{U}(0, 10) & \nu &\sim \mathcal{N}(0, 3) \\ \zeta &\sim \mathcal{U}(-20, -5) & \xi &\sim \mathcal{U}(-10, 5) & \delta &\sim \mathcal{U}(0, 20) & \Gamma_0 &\sim \text{Beta}(0,5, 0,5) \end{aligned}$$

La distribución prior de Γ_0 es la prior de Jeffreys [18].

Tras aplicar el método MCMC con 4 cadenas de 10000 iteraciones cada una, descartando la mitad de las iteraciones como se ha comentado previamente, hemos obtenido las trazas y densidades de las distribuciones posteriores mostradas en la figura 4.1.




Figura 4.1: *Traza de la convergencia del modelo con el banco de datos original.*

Se puede observar que el modelo no incorpora la información de los datos correctamente para el parámetro δ . No podemos pensar que la razón sea que la prior no es suficientemente vaga y sesga sus valores, ya que alcanza valores de 20. Recordamos que la interpretación del parámetro δ es la tasa de diagnóstico erróneo; luego, si su valor es 20, esto hace que la probabilidad de diagnóstico erróneo un día después de la aparición del tumor sea aproximadamente $2,06 \times 10^{-9}$, un valor demasiado pequeño acorde con los estudios sobre el diagnóstico de tumor de CRC por TAC [21]. Así pues, incluso en el caso de que convergiese a una uniforme de mayor soporte, su convergencia no sería de utilidad.

Por esta razón volvemos a aplicar el modelo a nuestros bancos de datos sintéticos. Para los datos con seguimientos cortos, las trazas y distribuciones posteriores de los parámetros se pueden ver en la figura 4.2 mientras que para los datos con seguimientos largos, 4.3. Por otro lado, en la tabla 4.1 se muestran los valores de las estimaciones del estadístico de Gelman-Rubin y en la tabla 4.2 los valores de ESS (Effective Sample Size).

Parámetro	5 tomas		10 tomas	
	Est. puntual	I.C. superior	Est. puntual	I.C. superior
σ	1.01	1.04	1.01	1.04
β	1.13	1.34	1.15	1.39
ν	1.01	1.04	1.03	1.10
σ_b	1.02	1.07	1.17	1.45
δ	1.03	1.05	1.08	1.24
ζ	1.17	1.49	1.01	1.03
ξ	1.17	1.49	1.03	1.07

Cuadro 4.1: *Estadístico de Gelman-Rubin para los dos modelos.*




Figura 4.2: Traza de la convergencia del modelo con el banco de datos con seguimiento corto, 5 tomas.

	σ	β	ν	σ_b	δ	ζ	ξ
5 tomas	3130	1164	806	718	1436	82	64
10 tomas	3867	1019	1785	72	1689	944	205

Cuadro 4.2: Valores de ESS de las variables atendiendo a los datos de entrenamiento.

Las compilaciones del modelo con los distintos bancos de datos han durado 80,6 *seg.* para el banco pequeño y 124 *seg.* para el grande. Como puede apreciarse en los valores del estadístico de Gelman-Rubin, cuadro 4.1, ninguno de los dos bancos de datos consigue que todas las variables converjan correctamente, siendo siempre σ_b la variable con un mayor valor en general. Al ser un parámetro en un nivel más alto del modelo, es comprensible que el algoritmo presente más dificultades en estimar este parámetro, ya que todas las posibles desviaciones cometidas en variables en niveles más bajos del modelo afectan al valor de este.




Figura 4.3: Traza de la convergencia del modelo con el banco de datos con seguimiento largo, 10 tomas.

	σ	β	ν	σ_b	δ	ζ	ξ
Simulación							
Valores	2.5	0.2	0.5	0.5	0.075	-8	-2
5 tomas							
$Q_{0,025}$	2.189	0.195	0.034	1.130	0.033	-19.022	-8.762
Media	2.437	0.198	0.442	1.648	0.083	-10.967	-2.939
$Q_{0,975}$	2.732	0.202	1.046	2.352	0.226	-7.624	-0.338
10 tomas							
$Q_{0,025}$	2.326	0.199	0.372	0.053	0.042	-8.956	-8.703
Media	2.502	0.200	0.697	0.280	0.108	-7.892	-0.396
$Q_{0,975}$	2.696	0.202	1.049	0.796	0.312	-7.293	8.329

Cuadro 4.3: Resúmenes numéricos de las cadenas. En la primera fila, llamada *Simulación*, se tienen los valores de los parámetros con los que se han generado los datos.

En el cuadro 4.3 se recogen las estimaciones de los intervalos de confianza y las medias de los parámetros. Los valores de los estimadores de Gelman y Rubin apuntan a que el entremezclado de las cadenas no es óptimo y, por tanto, las estimaciones de los intervalos de confianza pueden no ser muy fiables. Sin embargo, la inspección visual de las trazas sugiere que las estimaciones de las medias pueden ser adecuadas para ambos conjuntos de datos.

Para algunos parámetros como la variabilidad de la media del nivel de VAF por paciente y toma, σ , o la tasa de crecimiento del VAF tras la aparición del tumor, β , el modelo recupera sus valores correctamente. Otras estimaciones medias como las del nivel basal poblacional de VAF, ν , la tasa de detección por imagen del tumor, δ , son cercanas a los valores originales aunque no lo suficiente como para decir que se recuperan. Por otro lado, las medias de las cadenas de los parámetros relacionados

con el riesgo de desarrollo tumoral, ζ y ξ , y la heterogeneidad interindividual del nivel medio de VAF, σ_b , distan de los valores originales.

En relación al riesgo, al trabajar con seguimientos cortos, el modelo no detecta correctamente ninguno de los dos parámetros. Sin embargo, al trabajar con seguimientos largos sí detecta correctamente el riesgo basal del desarrollo tumoral, ζ , pero a costa de reducir ξ y, por tanto, la relación entre el riesgo y el nivel medio de VAF propio de cada paciente. Esto último puede entenderse mejor con la ecuación del riesgo, 3.1. Al hacer esto, el modelo menosprecia el riesgo individual de cada paciente y considera que todos los pacientes tienen un riesgo muy similar de desarrollar el tumor, o al menos que éste no se plasma en el nivel de VAF.

Finalmente, la heterogeneidad interindividual del nivel de VAF, σ_b , es el parámetro que al modelo le cuesta más identificar. Con seguimientos cortos la sobrestima mientras que con seguimientos largos la subestima. Como hemos mencionado previamente, al ser un parámetro de un nivel más alejado de las variables observadas, es comprensible que sea el parámetro con más dificultades para estimar.

Todo esto muestra que este modelo no es aplicable. Incluso en el caso de que la relación entre el desarrollo del CRC y el VAF siga la estructura descrita por el modelo, este no es capaz de reconocerla correctamente. Al trabajar con seguimientos largos, las aproximaciones son mejores, pero, como hemos mencionado previamente, comete errores y uno de ellos es subestimar la predisposición individual del paciente al desarrollo del tumor. A pesar de esto, el modelo puede ser útil para la predicción.

4.1.2. Predicción

Para la predicción consideraremos un nuevo banco de datos de 15 pacientes con seguimientos entre 2 y 15 tomas. Este banco de datos se ha generado siguiendo la misma estructura explicada en la sección 3.3.




Figura 4.4: Gráfica con los datos de los pacientes para la predicción siguiendo la leyenda anterior.

Nuestro objetivo será analizar el poder predictivo del modelo en tomas aisladas y en seguimientos completos. Para lograr esto, aplicaremos el modelo a cada toma del seguimiento; de esta forma, replicamos el uso del modelo en casos reales donde se aplica tras el análisis del VAF en cada toma. Recordemos que dependiendo del tamaño de los seguimientos se han obtenido unas distribuciones posteriores diferentes, por lo que aplicaremos el modelo sobre los datos nuevos con ambas distribuciones prior y las medias de los parámetros como puntos de inicialización de las cadenas. De esta forma podremos comparar el poder predictivo del modelo tanto a corto como a largo plazo. Para facilitar la comprensión del lector, nos referiremos a las predicciones como predicción 1 para la resultante de aplicar las distribuciones posteriores del modelo con los datos sintéticos de seguimiento corto y predicción 2 para la resultante de las posteriores de los datos de seguimiento largo.

Gracias al paquete `fitdistrplus` [10], hemos podido estudiar la kurtosis y la simetría de las distribuciones posteriores.

Las distribuciones posteriores de las simulaciones del modelo con los datos cortos, y por tanto las prior de la predicción 1, pueden aproximarse por las siguientes distribuciones:

$$\begin{aligned} \beta &\sim \mathcal{N}(0,2, 0,01) & \sigma &\sim \mathcal{N}(2,44, 0,14) & \sigma_b &\sim \log(\mathcal{N})(0,49, 0,19) \\ \nu &\sim \text{Beta}(1,76, 4,69) & \zeta &\sim \text{Beta}(2, 1,23) & \xi &\sim \text{Beta}(2,95, 2) & \delta &\sim \mathcal{U}(0, 0,6) \end{aligned}$$

Para los parámetros ν , ξ y ζ , sus kurtosis y simetría concuerdan con la distribución Beta, pero su soporte es distinto al propio de la distribución. Se han aplicado transformaciones lineales para que los datos concuerden con las distribuciones. Por otro lado, la densidad de δ no se corresponde con ninguna distribución, por lo que hemos optado por usar como prior una uniforme con los límites obtenidos tras la compilación del modelo.

El modelo ha tardado 99,6 *seg.* en hacer 80 predicciones, es decir, una media de 1,24 *seg./pred.*. Este es un tiempo muy asequible para su uso cotidiano.

Por otro lado, las distribuciones posteriores obtenidas con el segundo banco de datos generado son:

$$\begin{aligned} \beta &\sim \mathcal{N}(0,2, 0,0007) & \sigma &\sim \mathcal{N}(2,5, 0,09) & \sigma_b &\sim \text{Beta}(1,36, 3,92) \\ \nu &\sim \mathcal{N}(0,7, 0,17) & \zeta &\sim -\log(\mathcal{N})(2,07, 0,05) & \xi &\sim \mathcal{N}(-0,39, 4,13) & \delta &\sim \log(\mathcal{N})(-2,2, 0,51) \end{aligned}$$

Al contrario que con las distribuciones anteriores, aquí la simetría y kurtosis de δ sí coinciden con una distribución, la log-normal. De la misma forma que antes, para σ_b se han aplicado transformaciones lineales.


El modelo ha tardado 114,23 *seg.* en hacer 80 predicciones, por tanto, presenta una media de 1,43 *seg./pred.*. Es un tiempo medio más elevado que al usar las otras distribuciones prior, sin embargo continúa siendo un buen tiempo.

El siguiente paso es fijar un límite a partir del cual el modelo prediga que un paciente presenta cáncer, es decir, fijar un umbral para $\mathbb{P}(\mathbf{C} = 1 \mid \text{datos})$ a partir del cual nuestro modelo afirme que el paciente presenta o no tumor. Para ello usaremos una gráfica ROC. Esta gráfica hace uso de las predicciones hechas para comparar el ratio de verdaderos positivos (true positive rate, TPR) y el ratio de falsos positivos (false positive rate, FPR). Estos ratios se definen como la *sensibilidad* y la $1 - \text{especificidad}$. Diferenciaremos entre *especificidad por toma* y *especificidad por paciente*. En la especificidad por toma, cada observación se considera de forma independiente, mientras que en la especificidad por paciente se

considera el seguimiento completo del individuo, considerando como verdadero negativo el no predecir que un paciente presente cáncer en ninguna de sus tomas.

El umbral óptimo es aquel que se acerque más al punto $TPR = 1$ $FPR = 0$, es decir, aquel que maximiza los verdaderos positivos y minimiza los falsos positivos. En nuestras gráficas son los puntos más cercanos a la esquina superior izquierda de la gráfica. Para encontrar el umbral se suele considerar como método maximizar $TPR + FPR$; sin embargo, en los casos clínicos como este suele ser preferible minimizar los falsos positivos a costa de aumentar los verdaderos positivos, ya que es preferible cometer un error identificando a un paciente sano como enfermo que al revés. Compararemos el umbral óptimo con el umbral marcado por $\mathbb{P}(C = 1) = 0,5$.

Predicción 1



Predicción 2




Figura 4.5: Aquí mostramos las gráficas ROC para ambas prior, la superior con las prior de los datos de seguimiento corto, predicción 1, y la inferior de los seguimientos largos, predicción 2. En las gráficas, las etiquetas de los umbrales siguen el patrón 'umbral'('TPR', 'FPR')

En la figura 4.5 podemos encontrar las distintas gráficas ROC, siendo las superiores las asociadas a la predicción 1 y las inferiores a la predicción 2. En todos los casos el umbral óptimo es inferior al umbral $\mathbb{P}(\mathbf{C} = 1) = 0,5$, pero es más próximo a la esquina superior izquierda.

Para la predicción 1, el umbral óptimo por toma es $\mathbb{P}(\mathbf{C} = 1) = 0,32$ el cual presenta un TPR = 0,77 y un FPR = 0,1, es decir, detecta el 77 % de los tumores y clasifica el 10 % de las tomas provenientes de pacientes sanos como tomas de pacientes con tumor. Por otro lado, el umbral $\mathbb{P}(\mathbf{C} = 1) = 0,5$ mejora la sensibilidad del modelo en un 1 % a costa de reducir la especificidad en un 5 %. Dado que el modelo está pensado como detección primaria seguida de una confirmación por TAC, y no como determinante para el diagnóstico, parece más conveniente el umbral $\mathbb{P}(\mathbf{C} = 1) = 0,5$ aunque esto debería consultarse con expertos clínicos.

En cuanto al umbral por paciente de la predicción 1, vemos que el umbral óptimo y el punto $\mathbb{P}(\mathbf{C} = 1) = 0,5$ ofrecen la misma sensibilidad; por tanto, la mejor selección es el umbral $\mathbb{P}(\mathbf{C} = 1) = 0,41$, ya que minimiza los falsos positivos por paciente.

Por otra parte, los mejores umbrales para la predicción 2 son $\mathbb{P}(\mathbf{C} = 1) = 0,5$ por toma y $\mathbb{P}(\mathbf{C} = 1) = 0,23$ por paciente. La selección del umbral por toma se basa en la mejora en la sensibilidad a cambio de un coste bajo en la especificidad que ofrece, mientras que para el umbral por paciente el punto seleccionado se encuentra por encima de la recta TPR = FPR, no como el punto $\mathbb{P}(\mathbf{C} = 1) = 0,5$ que comete más falsos positivos que verdaderos positivos.




Figura 4.6: Aquí mostramos las probabilidades calculadas por el modelo en el seguimiento de 9 de los pacientes simulados.

Otra medida de interés es el área bajo la curva, AUC. Esta medida representa la capacidad clasificadora del modelo, siendo un modelo que presente $AUC = 0,5$ un modelo sin capacidad clasificatoria, equivalente a una clasificación aleatoria, y un modelo con $AUC = 1$ un modelo capaz de clasificar perfectamente. En nuestro caso, los AUC son muy cercanos a 0,85 para las predicciones aisladas y a 0,66 y 0,55 para el seguimiento completo de los pacientes. Esto muestra que el modelo no es un mal criterio de clasificación en tomas aisladas, aunque al considerar un seguimiento completo no muestre una mejora significativa frente a una clasificación aleatoria.

Así pues, como la predicción 1 muestra mejores valores de AUC tanto en tomas aisladas como en seguimientos completos, las distribuciones posteriores resultantes de aplicar el modelo a seguimientos cortos son mejores para considerar como prior en la predicción.

Todo esto muestra que el modelo es una buena herramienta de apoyo a lo largo del seguimiento de los pacientes con riesgo de desarrollar CRC, sobre todo al trabajar con seguimientos cortos.

Capítulo 5

Discusión y Conclusiones

El cáncer constituye la enfermedad más estudiada por su alta mortalidad y por la falta de un tratamiento completamente efectivo. Dentro de los distintos tipos, el CRC es uno de los casos más comunes y mortales, además de uno de los más difíciles de diagnosticar. Como en el resto de los cánceres, cuanto más tardío sea el diagnóstico, menos probabilidades de éxito tiene el paciente. Además de las dificultades que presenta la enfermedad de por sí se suman las dificultades logísticas, económicas y administrativas propias de la sanidad actual, por lo que nos encontramos ante un marco clínico muy complejo. Las últimas investigaciones apuntan al nivel de ADN tumoral circulante como el biomarcador óptimo para estudiar el desarrollo de la enfermedad.

En este trabajo se ha propuesto un posible modelo para la rápida detección del desarrollo de esta enfermedad, agilizando de esta forma los seguimientos de los pacientes. El modelo propuesto integra el análisis de supervivencia con cadenas de Markov dentro de un marco teórico y de inferencia Bayesianos. Debido a las dificultades que presentan los datos clínicos reales, no se ha podido estudiar la correspondencia del modelo con la realidad; sin embargo, hemos estudiado su aplicabilidad y comportamiento predictivo gracias al uso de datos sintéticos. De esta forma podemos conocer si, en caso de que el CRC siga una estructura similar a la marcada con nuestro modelo, este sería útil o no.

Gracias a aplicar el modelo sobre dos conjuntos de datos distintos, variando la longitud de los seguimientos, hemos podido comprobar que cuando el modelo trabaja con seguimientos largos, pierde sensibilidad respecto a la influencia del nivel basal de VAF propio de cada paciente sobre el riesgo del desarrollo de la enfermedad. Esto hace que el modelo no detecte correctamente el proceso que sigue la enfermedad y no lo haga aplicable a casos clínicos reales, ya que el seguimiento postoperatorio de los pacientes suele constar de entre 10 y 20 tomas.

En cuanto a su capacidad predictiva, el modelo ha mostrado ser de utilidad a la hora de detectar el riesgo de desarrollo de CRC tanto en tomas aisladas como en seguimientos completos. Es importante hacer énfasis en que el modelo mejora sus predicciones con seguimientos de corta duración; por tanto, mejora su utilidad en la primera y más crítica etapa del seguimiento posquirúrgico de pacientes sometidos a resección quirúrgica de un tumor de cáncer colorrectal.

Por otro lado, no hemos de obviar la complejidad de la estructura latente del modelo. Al ser un modelo Bayesiano de cinco niveles que se asienta en dos únicas variables observadas, la carga de información es muy elevada. Una de las opciones a valorar con la continuación del estudio sería considerar una simplificación del modelo asentándose siempre en la literatura médica, como por ejemplo fijar la

variable δ respecto a las conclusiones del artículo de S.Mangat et al. [21]. Otra opción a considerar sería aplicar el método **SHELF** para una elicitación de las prior más acertada; esto podría también marcar una mejora sustancial en la convergencia del modelo.

En conclusión, aunque el modelo requiere de una validación más detallada y posiblemente reajustes para su aplicación clínica real, los resultados obtenidos sugieren que este modelo puede ser la base de una herramienta estadística prometedora para el seguimiento de pacientes en riesgo de desarrollar CRC. Asimismo, este trabajo muestra el potencial de la aplicación de las herramientas Bayesianas en el desarrollo de estrategias predictivas dentro del campo de la oncología.

Bibliografía

- [1] American Cancer Society. (2026). *¿Qué causa el cáncer colorrectal?* <https://www.cancer.org/es/cancer/tipos/cancer-de-colon-o-recto/causas-riesgos-prevencion/que-lo-causa.html>
- [2] Amoros Salvador, R., King, R., Toyoda, H., Kumada, T., Johnson, P. J., & Bird, T. G. (2019). A continuous-time hidden Markov model for cancer surveillance using serum biomarkers with application to hepatocellular carcinoma. *METRON*, 77, 67-86. <https://doi.org/10.1007/s40300-019-00151-8>
- [3] Berger, J. O., & Wolpert, R. L. (1988). *The Likelihood Principle* (2.^a ed., Vol. 6). Institute of Mathematical Statistics.
- [4] Bernardo, J. M. (1979). Reference Posterior Distributions for Bayesian Inference. *Journal of the Royal Statistical Society: Series B (Methodological)*, 41(2), 113-128. <https://doi.org/10.1111/j.2517-6161.1979.tb01066.x>
- [5] Brémaud, P. (2020). *Markov Chains: Gibbs Fields, Monte Carlo Simulation and Queues* (2.^a ed., Vol. 31). Springer. <https://doi.org/10.1007/978-3-030-45982-6>
- [6] Dasari, A., Morris, V. K., Allegra, C. J., Atreya, C., Benson, A. B., Boland, P., Chung, K., Copur, M. S., Corcoran, R. B., Deming, D. A., Dwyer, A., Diehn, M., Eng, C., George, T. J., Gollub, M. J., Goodwin, R. A., Hamilton, S. R., Hechtman, J. F., Hochster, H., ... Kopetz, S. (2020). ctDNA applications and integration in colorectal cancer: an NCI Colon and Rectal–Anal Task Forces whitepaper. *Nature Reviews Clinical Oncology*, 17(12), 757-770. <https://doi.org/10.1038/s41571-020-0392-0>
- [7] de Finetti, B. (1974). *Theory of Probability*. Wiley.
- [8] de Valpine, P., Paciorek, C., Turek, D., Michaud, N., Anderson-Bergman, C., Obermeyer, F., Wehrhahn Cortes, C., Rodríguez, A., Temple Lang, D., & Paganin, S. (2026). *NIMBLE: MCMC, Particle Filtering, and Programmable Hierarchical Modeling* [R package version 1.4.1]. Ver. 1.4.1. <https://doi.org/10.5281/zenodo.1211190>
- [9] de Valpine, P., Turek, D., Paciorek, C., Anderson-Bergman, C., Temple Lang, D., & Bodik, R. (2017). Programming with models: writing statistical algorithms for general model structures with NIMBLE. *Journal of Computational and Graphical Statistics*, 26, 403-413. <https://doi.org/10.1080/10618600.2016.1172487>
- [10] Delignette-Muller, M. L., & Dutang, C. (2015). fitdistrplus: An R Package for Fitting Distributions. *Journal of Statistical Software*, 64(4), 1-34. <https://doi.org/10.18637/jss.v064.i04>
- [11] *EU guidelines for colorectal cancer screening and diagnosis*. (2025). International Agency for Research on Cancer. https://cci4eu.aws-lcb.iarc.who.int/wp-content/uploads/2025/01/EU-guidelines_CRC-screening-and-diagnosis.pdf

- [12] Gelman, A., Carlin, J. B., Stern, H. S., Dunson, D. B., Vehtari, A., & Rubin, D. B. (2013). *Bayesian Data Analysis* (3.^a ed.). CRC Press.
- [13] Gelman, A., & Rubin, D. B. (1992). Inference from Iterative Simulation Using Multiple Sequences. *Statistical Science*, 7(4), 457-511. <https://doi.org/10.1214/ss/1177011136>
- [14] Geman, S., & Geman, D. (1984). Stochastic Relaxation, Gibbs Distributions, and the Bayesian Restoration of Images. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 6(6), 721-741. <https://doi.org/10.1109/TPAMI.1984.4767596>
- [15] Henriksen, T. V., Tarazona, N., Frydendahl, A., Reinert, T., Gimeno-Valiente, F., Carbonell-Asins, J. A., Sharma, S., Renner, D., Hafez, D., Roda, D., Huerta, M., Roselló, S., Madsen, A. H., Løve, U. S., Andersen, P. V., Thorlacius-Ussing, O., Iversen, L. H., Gotschalck, K. A., Sethi, H., & Andersen, C. L. (2021). Circulating Tumor DNA in Stage III Colorectal Cancer, beyond Minimal Residual Disease Detection, toward Assessment of Adjuvant Therapy Efficacy and Clinical Behavior of Recurrences. *Clinical Cancer Research*, 28(3), 507-517. <https://doi.org/10.1158/1078-0432.CCR-21-2404>
- [16] International Agency for Research on Cancer. (2024). *Global Cancer Observatory Data Visualization Tool*. https://gco.iarc.fr/today/en/dataviz/bars?mode=cancer&group_populations=1&key=total
- [17] Jaynes, E. T. (2003). *Probability Theory: The Logic of Science*. Cambridge University Press.
- [18] Jeffreys, H. (1961). *Theory of Probability* (3.^a ed.). Oxford University Press.
- [19] Kass, R. E., & Wasserman, L. (1996). The Selection of Prior Distributions by Formal Rules. *Journal of the American Statistical Association*, 91(435), 1343-1370. <https://doi.org/10.1080/01621459.1996.10477003>
- [20] Kruschke, J. K. (2015). *Doing Bayesian Data Analysis: A Tutorial with R, JAGS, and Stan* (2.^a ed.). Academic Press.
- [21] Mangat, S., Kozoriz, M., Bicknell, S., & Spielmann, A. (2018). The Accuracy of Colorectal Cancer Detection by Computed Tomography in the Unprepared Large Bowel in a Community-Based Hospital. *Canadian Association of Radiologists Journal*, 69, 92-96. <https://doi.org/10.1016/j.carj.2017.12.005>
- [22] Nakamura, Y., Watanabe, J., Akazawa, N., Hirata, K., Kataoka, K., Yokota, M., Kato, K., Kotaka, M., Kagawa, Y., Yeh, K.-H., Mishima, S., Yukami, H., Ando, K., Miyo, M., Misumi, T., Yamazaki, K., Ebi, H., Okita, K., Hamabe, A., ... Oki, E. (2024). ctDNA-based molecular residual disease and survival in resectable colorectal cancer. *Nature Medicine*, 30(11), 3272-3283. <https://doi.org/10.1038/s41591-024-03254-6>
- [23] Norris, J. R. (1997). *Markov Chains*. Cambridge University Press. <https://doi.org/10.1017/CBO9780511810633>
- [24] O'Hagan, A., Buck, C. E., Daneshkhah, A., Eiser, J. R., Garthwaite, P. H., Jenkinson, D. J., Oakley, J. E., & Rakow, T. (2006). *Uncertain Judgements: Eliciting Experts' Probabilities*. John Wiley & Sons. <https://doi.org/10.1002/0470033312>
- [25] Rizopoulos, D. (2012). *Joint Models for Longitudinal and Time-to-Event Data: With Applications in R*. Chapman & Hall/CRC. <https://doi.org/10.1201/b12208>
- [26] Schwarz, G. (1978). Estimating the Dimension of a Model. *The Annals of Statistics*, 6(2), 461-464. <https://doi.org/10.1214/aos/1176344136>

- [27] Spiegelhalter, D. J., Best, N. G., Carlin, B. P., & van der Linde, A. (2002). Bayesian Measures of Model Complexity and Fit. *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, 64(4), 583-639. <https://doi.org/10.1111/1467-9868.00353>
- [28] Tarazona, N., Gimeno-Valiente, F., Gambardella, V., Zuñiga, S., Rentero-Garrido, P., Huerta, M., Roselló, S., Martinez-Ciarpaglini, C., Carbonell-Asins, J. A., Carrasco, F., Ferrer-Martínez, A., Bruixola, G., Fleitas, T., Martín, J., Tébar-Martínez, R., Moro, D., Castillo, J., Espí, A., Roda, D., & Cervantes, A. (2019). Targeted next-generation sequencing of circulating-tumor DNA for tracking minimal residual disease in localized colon cancer. *Annals of Oncology*, 30(11), 1804-1812. <https://doi.org/10.1093/annonc/mdz390>
- [29] Vail, E., Choubey, A. P., Alexander, H. R., August, D. A., Berry, A., Boland, P. M., Eskander, M. F., Grandhi, M. S., Haliani, B., In, H., Kennedy, T. J., Langan, R. C., Maggi, J. C., Pitt, H. A., Ganesan, S., & Ecker, B. L. (2024). Recurrence-free survival dynamics following adjuvant chemotherapy for resected colorectal cancer: A systematic review of randomized controlled trials. *Cancer Medicine*, 13(1), e6884. <https://doi.org/10.1002/cam4.6884>
- [30] Vehtari, A., Gelman, A., Simpson, D., Carpenter, B., & Bürkner, P.-C. (2021). Rank-normalization, folding, and localization: An improved $\hat{R}$ for assessing convergence of MCMC. *Bayesian Analysis*, 16(2), 667-718. <https://doi.org/10.1214/20-BA1221>
- [31] World Cancer Research Fund. (2024). *Colorectal cancer statistics*. <https://www.wcrf.org/preventing-cancer/cancer-statistics/colorectal-cancer-statistics>
- [32] Zhou, Q., Chen, X., Zeng, B., Zhang, M., Guo, N., Wu, S., Zeng, H., & Sun, F. (2025). Circulating tumor DNA as a biomarker of prognosis prediction in colorectal cancer: a systematic review and meta-analysis. *Journal of the National Cancer Center*, 5(2), 167-178. <https://doi.org/10.1016/j.jncc.2024.05.007>